

# Maths

---

## 雅可比矩阵 Jacobi Matrix

---

差分方程系统？

## 黑塞矩阵 Hessian Matrix

---

## 仿射函数 Affine Function

---

形如  $f(x) = a + bx$ 。对应的，严格意义上的线性函数是  $f(x) = bx, a = 0$

性质

1. 当且仅当  $f''(x) \equiv 0$
2. 当且仅当对  $\forall 0 \leq p \leq 1, f[pu + (1-p)v] \equiv pf(u) + (1-p)f(v)$ ，即凸组合直接可分

## 位似函数 Homothetic Function

---

（一次）齐次函数的单调变换

$f(\mathbf{x})$  是一个位似函数当且仅当它可以表示成  $f(\mathbf{x}) = g(h(\mathbf{x}))$ ，其中  $h(\cdot)$  是（一次）齐次函数， $g(\cdot)$  是（正的）单调函数

## 欧拉法则

---

如果  $f$  是一个可微的一次齐次函数，那么

$$f(\mathbf{x}) = \sum_{i=1}^n \frac{\partial f(\mathbf{x})}{\partial x_i} x_i \quad (1)$$

证明为对恒等式  $f(t\mathbf{x}) \equiv tf(\mathbf{x})$  两边对  $t$  求微分，然后令  $t = 1$

## 分析

---

紧集：特殊情况下简单理解  $S \subset R^n$  是有界的闭集，那么  $S$  是紧集。

注意有/无界和集合开闭并不存在一一对应关系，也就是可以存在无界的闭空间。从度量？点集拓扑领域？角度理解？

两个例子：

- 如果全集选取为有理数集，则  $\mathbb{R}$  既是开集也是闭集，其补集  $\emptyset$  空集也是既开又闭
- 如果全集选取为  $R^n$ ，则实数轴应该为闭集；如果全集就是实数轴，那实数轴应该既开又闭

## 矩阵定性

---

### 正定

$\Leftrightarrow$  特征值全部大于零

$\Leftrightarrow$  顺序主子式全为正

$\Leftrightarrow$  存在实可逆矩阵  $C$ ，分解为  $A = C^T C$ ；就是和  $E$  合同

$\Leftrightarrow$  存在秩为  $n$  的  $m \times n$  实矩阵  $B$ ，使  $A = B^T B$

$\Leftrightarrow$  存在主对角元素全为正的实三角矩阵  $R$ ，使  $A = R^T R$

$\Rightarrow$  逆矩阵也正定

$\Rightarrow$  对角线元素均为正数

### 负定

$\Leftrightarrow$  特征值全部小于零

$\Leftrightarrow$  顺序主子式的符号为  $(-1)^k$

$\Rightarrow$  逆矩阵也负定

$\Rightarrow$  对角线元素均为负数

### 半定

对所有  $\mathbf{x}$  都有  $\mathbf{x}^T A \mathbf{x} \begin{pmatrix} \leq \\ \geq \end{pmatrix} 0$ ，即允许当  $\mathbf{x} \neq \mathbf{0}$  时  $\mathbf{x}^T A \mathbf{x} = 0$  仍成立，放松了要求

### 半正定

$\Leftrightarrow$  顺序主子式非负

$\Leftrightarrow$  特征值全部非负

$\Leftrightarrow$  存在实矩阵  $C$ ，分解为  $A = C^T C$

### 半负定

### 约束条件下的定性

如果不要对  $\forall \mathbf{x}$ ,  $\mathbf{x}^T A \mathbf{x}$  都要有确定的符号, 而只是要求某些限定的  $\mathbf{x}$  成立, 比如说满足  $\mathbf{b}^T \mathbf{x} = 0$  且  $\mathbf{x} \neq \mathbf{0}$  的  $\mathbf{x}$ 。我们就称为  $A$  在约束条件下的定性。具体可以用 **加边黑塞矩阵** (增广黑塞矩阵) 来进行判断

$$\begin{pmatrix} 0 & b_1 & \cdots & b_n \\ b_1 & a_{11} & \cdots & a_{1n} \\ \vdots & \vdots & & \vdots \\ b_n & a_{n1} & \cdots & a_{nn} \end{pmatrix} \quad (2)$$

- 约束下正定, 当且仅当加边黑塞矩阵主子式均为负 (注意这和原来的单纯正定刚好相反)
- 约束下负定, 当且仅当加边黑塞矩阵主子式符号为  $(-1)^k$ ,  $k = 2, 3, \dots, n$  (这个却和单纯负定一致)

这个加边矩阵的来历是基于约束下的拉格朗日方法

特别地, 如果黑塞矩阵在约束下是负定的 (不止是半负定), 那么我们称函数有 **正则最大值** (Regular Maximum)。一个正则最大值肯定是一个严格的局部最大值, 但反之不一定

## 梯度 Gradient

考虑一个线性泛函  $f: R^n \rightarrow R$ ,  $f$  在  $\mathbf{x}^*$  的梯度是一个向量, 其坐标就是该处的各个偏导数

$$\mathbf{D}f(\mathbf{x}^*) = \left( \frac{\partial f(\mathbf{x}^*)}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x}^*)}{\partial x_n} \right) \quad (3)$$

注意梯度有其方向, 并且指向  $f$  增加最快的方向。证明为取一个单位向量  $\mathbf{h}$ ,  $f$  在  $\mathbf{x}^*$  处沿  $\mathbf{h}$  方向的导数即为  $\mathbf{D}f(\mathbf{x}^*)\mathbf{h}$ 。内积为  $\mathbf{D}f(\mathbf{x}^*)\mathbf{h} = |\mathbf{D}f(\mathbf{x}^*)|\cos\theta$ 。显然当  $\theta = 0$  时亦即两向量共线时取到最大值

## 超平面 Hyperplane

对于法向量  $\omega$ , 超平面公式可以写为  $\omega^T x + b = 0$

## 切平面 Tangent Hyperplane

$$H(a) = \{\mathbf{x} : \mathbf{D}f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) = 0\} \quad (4)$$

就是泰勒展开第二项的线性近似

如果  $\mathbf{x}$  是切超平面中的一个向量, 那么  $\mathbf{x} - \mathbf{x}^*$  与  $f$  在  $\mathbf{x}^*$  处的梯度是正交的

## 分离超平面

如果  $A$  和  $B$  是  $R^n$  中两个非空不相交的凸集，那么就可以从中插入一个超平面。存在一个线性泛函  $\mathbf{p}$ ，使得所有  $A$  中的  $\mathbf{x}$  和  $B$  中的  $\mathbf{y}$  都有  $\mathbf{p}\mathbf{x} \geq \mathbf{p}\mathbf{y}$  成立

## 凸组合

---

向量  $\mathbf{u}$  和  $\mathbf{v}$  的线性组合

$$\theta \mathbf{u} + (1 - \theta) \mathbf{v}, \quad (0 \leq \theta \leq 1) \quad (5)$$

可以解释为两个向量的加权平均

## 凸集 Convex Set

---

定义

几何上可以这么理解，要求点集无孔，边缘各处无缩进

$A$  是  $R^n$  中的一个点集，如果  $\mathbf{x}$  和  $\mathbf{y}$  都在  $A$  中，且他们的凸组合仍然在  $A$  中，则  $A$  是凸集。如果对于  $0 < t < 1$  的所有  $t$  都有  $t\mathbf{x} + (1 - t)\mathbf{y}$  在  $A$  的内部（取消了等于号），则称  $A$  为严格凸的

性质

凸集的和仍然是凸的

## 凸函数 Convex Function

---

定义

1. 几何直观定义：凸组合线段的高度大于等于凸组合函数值的高度；或者说总在切平面以上（或与之重合）

对于函数  $f$  定义域内任意两个不同的点  $u$  和  $v$ ，且相对于  $0 \leq \theta \leq 1$ ，当且仅当

$$\theta f(u) + (1 - \theta) f(v) \geq f[\theta u + (1 - \theta) v] \quad (6)$$

时， $f$  为凸函数

2. 函数可微时的定义：

若对于定义域内任意给定点  $u = (u_1, \dots, u_n)$  和另一给定点  $v = (v_1, \dots, v_n)$ ，当且仅当

$$f(v) \geq f(u) + \sum_{j=1}^n f_j(u)(v_j - u_j) \quad (7)$$

可微函数  $f$  为凸函数。其中  $f_j(u) \equiv \partial f / \partial x_j$  在  $u = (u_1, \dots, u_n)$  计算其值

3. 去掉等号即为严格凸

性质

## 1. 函数的和

1. 多个凸函数的和仍然是凸函数
2. 只要其中一个凸函数是严格凸的，那么多个凸函数的和就是严格凸的

## 2. 更大的拟凸的性质，拟凸函数可以引致一个凸集

$$S^{\leq} = \{x | f(x) \leq k\}, \quad [f(x) \text{ 为凸函数}, k \text{ 为任意常数}] \quad (8)$$

此下轮廓集为一个凸集

3. 严格凸函数的黑塞矩阵（一般）是正定的；凸函数的黑塞矩阵是半正定的。可以就此判别

## “凸”的语义差别

- 在集合中：凸描述的是集合中的点如何“填充”到一起。强调的是“内外之分”
- 在函数中：凸描述的是一条曲线或者曲面如何弯曲。强调的是“上下之分”

## 拟凸函数 QuasiConvex Function

### 定义

#### 1. 直观定义

对于  $\forall a \in (0, 1)$ ，都有  $f(ax + (1 - a)y) \leq \max\{f(x), f(y)\}$  成立。拟凹就是大于等于最小值

也就是说函数  $f$  图形上任意弧段  $MN$ （设点  $N$  高于或等于  $M$ ），除了两个端点以外这个弧段上任意一点高度都低于或等于点  $N$  的高度

#### 2. 轮廓集定义

对于任意常数  $k$ ，当且仅当

$$S^{\leq} \equiv \{x | f(x) \leq k\} \quad (9)$$

此下轮廓集是凸集时，函数  $f(x)$  是拟凸的。变量也可以是一个向量  $\mathbf{x}$ 。拟凹就是上轮廓集为凸集

### 性质

1.  $\text{凸} \subset \text{拟凸}$
2. 同时有凹凸区段的函数也可以是整体拟凹的，典型比如正态分布密度函数

### 判别

拟凹的矩阵条件

$$\begin{pmatrix} 0 & f_1 & f_2 & \cdots & f_n \\ f_1 & f_{11} & f_{12} & \cdots & f_{1n} \\ f_2 & f_{21} & f_{22} & \cdots & f_{2n} \\ \vdots & & & & \\ f_n & f_{n1} & f_{n2} & \cdots & f_{nn} \end{pmatrix} \quad (10)$$

注意此矩阵与矩阵定性部分约束条件下的判定矩阵不同，加边部分是自己的一阶导数而不是约束向量。

此矩阵的顺序主子式的符号为  $(-1)^k$  时， $f$  为拟凹

## 包络定理 Envelope Theorem

值函数 (Value Function) 为  $M(a) = f(x(a), a)$ ，其中自变量  $x$  根据参数  $a$  取得最优化。想要考察的是最优值如何对参数  $a$  变化作出反应，也就是  $\frac{\partial M}{\partial a}$

值函数两边对  $a$  求导

$$\frac{dM(a)}{da} = \frac{\partial f[x(a), a]}{\partial x} \frac{\partial x(a)}{\partial a} + \frac{\partial f[x(a), a]}{\partial a} \quad (11)$$

而由于  $x(a)$  已是最优化选择，所以一阶条件有

$$\frac{\partial f[x(a), a]}{\partial x} = 0 \quad (12)$$

从而原式只剩下

$$\frac{dM(a)}{da} = \frac{\partial f[x, a]}{\partial a} \Big|_{x=x(a)} \quad (13)$$

也就是说，值函数关于参数的全导数，等于在最优化选择的偏导数。参数  $a$  变化时有两个效应

- 直接影响  $f$
- 通过  $x$  间接影响  $f$

但因为最优化，间接效应等于零，只剩下直接效应

### 带有约束的情况

考虑如下值函数

$$\begin{aligned} M(a) &= \max_{x_1, x_2} g(x_1, x_2, a) \\ \text{s.t. } & h(x_1, x_2, a) = 0 \end{aligned} \quad (14)$$

注意到参数  $a$  可以同时出现在值函数和约束条件之中

对应拉格朗日函数  $L = g(x_1, x_2, a) - \lambda h(x_1, x_2, a)$ ，一阶条件为

$$\begin{aligned} \frac{\partial g}{\partial x_1} - \lambda \frac{\partial h}{\partial x_1} &= 0 \\ \frac{\partial g}{\partial x_2} - \lambda \frac{\partial h}{\partial x_2} &= 0 \\ h(x_1, x_2, a) &= 0 \end{aligned} \quad (15)$$

对值函数  $M(a) \equiv g(x_1(a), x_2(a), a)$  两边求导

$$\frac{dM}{da} = \frac{\partial g}{\partial x_1} \frac{dx_1}{da} + \frac{\partial g}{\partial x_2} \frac{dx_2}{da} + \frac{\partial g}{\partial a} \quad (16)$$

通过上一步的结果替换前两项

$$\frac{dM}{da} = \lambda \left( \frac{\partial h}{\partial x_1} \frac{dx_1}{da} + \frac{\partial h}{\partial x_2} \frac{dx_2}{da} \right) + \frac{\partial g}{\partial a} \quad (17)$$

而由于最优化，满足约束  $h(x_1(a), x_2(a), a) \equiv 0$ ，两边对  $a$  求微分

$$\frac{\partial h}{\partial x_1} \frac{dx_1}{da} + \frac{\partial h}{\partial x_2} \frac{dx_2}{da} + \frac{\partial h}{\partial a} = 0 \quad (18)$$

代入上式即可得到

$$\frac{dM}{da} = -\lambda \frac{\partial h}{\partial a} \Big|_{x=x(a)} + \frac{\partial g}{\partial a} \Big|_{x=x(a)} \quad (19)$$

总结来说也就和无约束情况类似，想要求值函数关于参数的变动情况，**直接将拉格朗日函数对该参数求导，并代入自变量的最优化取值**。同样只有直接效应没有间接效应

两个引理可以直接记忆为用求导代替除法，包络的思路是从等号右边推出左边，即从值函数最优化推出自变量如何跟随参数变动取得最优化

## 霍特林引理 Hotelling's lemma

通过利润函数求出净供给函数，已知  $\pi(\mathbf{p}) = \mathbf{p}\mathbf{y}(\mathbf{p})$

应用无约束包络定理

$$y_i(\mathbf{p}) = \frac{\partial \pi(\mathbf{p})}{\partial p_i} \Big|_{\mathbf{p}=\mathbf{p}^*} \quad i = 1, \dots, n \quad (20)$$

## 谢泼德引理 Shephard's lemma

通过成本函数求出要素需求函数，已知  $c(\mathbf{w}, y)$ ，约束条件  $f[\mathbf{x}(\mathbf{w}, y)] \equiv y$

应用有约束包络定理

$$x_i(\mathbf{w}, y) = \frac{\partial C(\mathbf{w}, y)}{\partial w_i} \quad i = 1, \dots, n \quad (21)$$

## 库恩-塔克条件 Kuhn-Tucker conditions

和 KKT 条件（Karush-Kuhn-Tucker conditions）是一回事。一般可粗略认为是求最值的**必要条件**，有多个极值解时要再比较

具体条件可以记忆为

$$\begin{aligned} \max_x \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, 2, \dots, q \\ & g_i(x) \leq 0, \quad i = 1, 2, \dots, p \end{aligned} \quad (22)$$

则

$$\begin{aligned} \nabla f(x^*) &= \sum_j \lambda_j \nabla h_j(x^*) + \sum_i \mu_i \nabla g_i(x^*) \\ \mu_i &\geq 0, \mu_i g_i(x^*) = 0 \end{aligned} \quad (23)$$

也就是说在极值处，目标函数的梯度（函数值增长最快的方向）可以表示为约束条件梯度的线性组合。  
注意这一条件移项后才是拉格朗日函数求梯度后的形式，这会导致拉格朗日乘子的符号相反！

以  $n$  个变量和  $m$  个不等式约束条件为例：

$$\begin{aligned} \max \quad & \pi = f(x_1, \dots, x_n) \\ \text{s.t.} \quad & g^i(x_1, \dots, x_n) \leq r_i \end{aligned} \quad (24)$$

第一步写出纯经典拉格朗日函数

$$Z = f(x_1, \dots, x_n) - \sum_{i=1}^m \lambda_i [g^i(x_1, \dots, x_n) - r_i] \quad (25)$$

注意  $\lambda$  后跟的约束条件符号方向最好保证和约束条件中的  $g^i(\mathbf{X})$  以及不等号方向一致， $\lambda$  前一律设为负号，方便与原条件统一记忆

- 确保对  $\lambda$  求偏导后写出的不等式条件符合原式约束要求
- $\lambda$  的符号：这里是求约束条件下的最大值，所以边界解时  $f$  的梯度  $\nabla f$  应该指向可行域  $g^i(\mathbf{X}) \leq r_i$  的外部（因为可行域为小于等于号），也就是说和  $\nabla g$  同向

库恩塔克条件具体为：

$$\text{最大化条件} \quad \frac{\partial Z}{\partial x_j} = 0 \quad (26)$$

$$\text{复述约束条件} \quad \frac{\partial Z}{\partial \lambda_j} \geq 0, \quad \text{拉格朗日乘数约束} \quad \lambda_i \geq 0, \quad \text{且} \quad \text{互补松弛条件} \quad \lambda_i \frac{\partial Z}{\partial \lambda_j} = 0$$

这里  $\lambda_i$  非负，表明  $\nabla f$  与  $\nabla g$  同向

如若换为最小化问题

$$\begin{aligned} \min \quad & \pi = f(x_1, \dots, x_n) \\ \text{s.t.} \quad & g^i(x_1, \dots, x_n) \leq r_i \end{aligned} \quad (27)$$

拉格朗日函数不变，当然可以用对偶化为  $\max \quad -\pi$ ，也可直接记忆为



$$\begin{aligned} \text{最小化条件 } \frac{\partial Z}{\partial x_j} &= 0 \\ \text{复述约束条件 } \frac{\partial Z}{\partial \lambda_j} &\geq 0, \quad \text{拉格朗日乘数约束 } \lambda_i \leq 0, \quad \text{且} \quad \text{互补松弛条件 } \lambda_i \frac{\partial Z}{\partial \lambda_j} = 0 \\ \text{这里 } \lambda_i &\text{非正, 因为求约束条件下最小值, 边界解时 } f \text{ 的梯度 } \nabla f \text{ 应该指向可行域 } g^i(X) \leq r_i \text{ 的内部} \\ &\text{因为可行域为小于等于号, 也就是说和 } \nabla g \text{ 反向} \end{aligned} \tag{28}$$

**互补松弛：**对某一变量的偏导与该变量不能同时非零，如  $f'(\lambda_i)\lambda_i = 0$ 。注意所涉及变量要对应

**约束规范：**边界的某些不规则性可能会使 KT 条件失效

**充分性定理**

## 集值映射下最优值的存在与连续性

考虑如下形式的最大化问题

$$\begin{aligned} M(a) &= \max f(\mathbf{x}, a) \\ \text{s.t. } \mathbf{x} &\in G(a) \end{aligned} \tag{29}$$

**最优值的存在性**

如果约束集  $G(a)$  是非空且紧的，函数  $f$  是连续的，那么这个最大化问题存在一个解  $\mathbf{x}^*$ 。注意  $R^n$  中的紧集也就是非空闭集，可能可以理解为类似于闭区间上连续函数必有最值

**最优值的唯一性**

如果函数  $f$  是严格凹的，且约束集是凸的，那么，若解存在，则它是唯一的

## 半连续性

**对应**（correspondence），即经济学家口中的多值函数。集值映射

## 最大值定理

令  $f(\mathbf{x}, a)$  为有一紧值域的一个连续函数，假设约束集  $G(a)$  是  $a$  的一个非空、紧值、连续的对应，那么：

1. 最大值  $M(a)$  是一个连续函数
2. 最大化问题中的解  $\mathbf{x}(a)$  是一个上半连续的对应

如果对应  $\mathbf{x}(a)$  恰好是单值的，使得  $\mathbf{x}(a)$  为一个函数，那么它将会是一个连续函数

## 可积性条件

对于一般如下形式带边界条件的偏微分方程组

$$\begin{aligned}\frac{\partial f(\mathbf{p})}{\partial p_i} &= g_i(f(\mathbf{p}, \mathbf{p})) \quad i = 1, \dots, n \\ f(\mathbf{q}) &= 0\end{aligned}\tag{30}$$

局部解存在的**必要条件**是交叉偏导数的对称性

$$\frac{dg_i}{dp_j} = \frac{dg_i}{df} \frac{\partial f}{\partial p_j} + \frac{\partial g_i}{\partial p_j} = \frac{\partial^2 f(\mathbf{p})}{\partial p_i \partial p_j} \stackrel{\text{交换 } i,j}{=} \frac{\partial^2 f(\mathbf{p})}{\partial p_j \partial p_i} = \frac{dg_j}{df} \frac{\partial f}{\partial p_i} + \frac{\partial g_j}{\partial p_i} = \frac{dg_j}{dp_i}\tag{31}$$

## 动态最优化

允许控制变量路径出现第一型间断点。也就是说允许状态变量路径出现尖点，只要分段可微

## 汉密尔顿函数 Hamiltonian Function

最大化典型问题（最小化就要另加负号），有自由终止状态（垂直终止线）

$$\begin{aligned}Max_u \quad V &= \int_0^T F(t, y, u) dt \\ s.t. \quad \frac{dy}{dt} &= f(t, y, u) \\ y(0) &= A, y(T) \text{自由} \quad (A, T \text{给定}) \\ u(t) &\in \mathcal{U} \text{对于所有 } t \in [0, T]\end{aligned}\tag{32}$$

其中

- $t$ , 时间变量
- $y$ , 状态变量
- $u$ , 控制变量
- $\lambda$ , 共态变量

### 汉密尔顿函数

$$H(t, y, u, \lambda) \equiv F(t, y, u) + \lambda(t)f(t, y, u)\tag{33}$$

最大值原理（一阶必要条件）

$$\begin{aligned}Max_u \quad H(t, y, u, \lambda) \quad &\text{对于所有 } t \in [0, T] \\ \frac{\partial H}{\partial \lambda} &= \frac{dy}{dt} \quad (y \text{的运动方程, 照抄约束条件}) \\ \frac{\partial H}{\partial y} &= -\frac{d\lambda}{dt} \quad (\lambda \text{的运动方程, 注意负号}) \\ \lambda(T) &= 0 \quad (\text{横截条件})\end{aligned}\tag{34}$$

注意第一个条件，是个比  $\frac{\partial H}{\partial u} = 0$  更宽泛的要求，因为可能会出现边界解。严格点还能再用二阶导数确定是最大值而不是最小值

## 横截条件

- 垂直终止线:  $\lambda(T) = 0$ , Ramsey model 常用就是这个
- 固定终止点:  $y(T) = y_T$
- 水平终止线:  $H_{t=T} = 0$
- 终止曲线  $y_T = \phi(T)$ :  $[H - \lambda\phi']_{t=T} = 0$
- 截断垂直终止线:  $\lambda(T) \geq 0, y_T \geq y_{min}, (y_T - y_{min})\lambda(T) = 0$
- 截断水平终止线:  $H_{t=T} \geq 0, T \leq T_{max}, (T - T_{max})H_{t=T} = 0$

求解时整合上面各式, 要求出控制变量的均衡值, 或者至少是其路径; 状态变量也可以对应求出

## 当前值汉密尔顿函数

被积函数增加了连续贴现因子  $e^{-\rho t}$ , 最优控制问题变为

$$\begin{aligned} \text{Max}_u V &= \int_0^T G(t, y, u) e^{-\rho t} dt \\ \text{s.t. } \frac{dy}{dt} &= f(t, y, u) \\ y(0) &= A, y(T) \text{ 自由 } (A, T \text{ 给定}) \\ u(t) &\in \mathcal{U} \text{ 对于所有 } t \in [0, T] \end{aligned} \quad (35)$$

定义一个新的当前值拉格朗日乘子  $m = \lambda e^{\rho t}$  从而有当前值汉密尔顿函数

$$H_c \equiv H e^{\rho t} = G(t, y, u) + m f(t, y, u) \quad (36)$$

## 当前值下的最大值原理

$$\begin{aligned} \text{Max}_u H_c(t, y, u, m) &\quad \text{对于所有 } t \in [0, T] \\ \frac{\partial H_c}{\partial m} &= \frac{dy}{dt} \quad (y \text{ 的运动方程, 照抄约束条件}) \\ \frac{\partial H_c}{\partial y} &= -\frac{dm}{dt} + \rho m \quad (\lambda \text{ 的运动方程, 注意负号, 多了 } \rho m \text{ 一项}) \\ m(T) e^{-\rho T} &= 0 \quad (\text{横截条件}) \end{aligned} \quad (37)$$

## 无穷水平下的问题

横截条件仍然和有限的一样, 只要取  $\lim_{T \rightarrow +\infty}$  即可 (应该)

## 欧拉方程

---

## 离散形式

两期间先转移一个微分量，然后这一转移带来的两期边际效用增减必须相等

例：某一资产定价为  $P_t$ ，每一期（在购买/出售交易前）会产生孳息  $D_t$ 。利率外生为  $r$ ，效用贴现率为  $\rho$ ，瞬时消费效用为 CRRA 变体  $u(C_t) = \ln C_t$ 。则考虑某一期减少消费去购买此资产，下一期出手，可以列出欧拉方程

$$dC \cdot d\ln C_t = E_t \left[ \frac{1}{1+\rho} \frac{dC}{P_t} (D_{t+1} + P_{t+1}) \cdot d\ln C_{t+1} \right] \quad (38)$$

如果不考虑购买资产，只是两期间消费转移

$$dC \cdot d\ln C_t = (1+r) \frac{1}{1+\rho} \cdot d\ln C_{t+1} \quad (39)$$

## 动态最优化形式

## 反推最优化问题